Алгоритм Бойера-Мура

Алгоритм Бойера-Мура

- Алгоритм поиска строки Бойера — Мура — алгоритм общего назначения, предназначенный для поиска подстроки в строке. Разработан Робертом Бойером и Джеем Муром в 1977 году. Преимущество этого алгоритма в том, что ценой некоторого количества предварительных вычислений над шаблоном, шаблон сравнивается с исходным текстом не во всех позициях — часть проверок пропускается как заведомо не дающая результата.
- В настоящее время алгоритм используется в текстовых редакторах и браузерах в команде Ctrl+F.

Основные идеи алгоритма

1. **Сканирование слева направо, сравнение справа налево.**

Совмещается начало текста (строки) и шаблона, проверка начинается с последнего символа шаблона. Если символы совпадают, производится сравнение предпоследнего символа шаблона и т. д. Если все символы шаблона совпали с наложенными символами строки, значит, подстрока найдена, и выполняется поиск следующего вхождения подстроки.

Если же какой-то символ шаблона не совпадает с соответствующим символом строки, шаблон сдвигается на несколько (вычисляется эвристиками) символов вправо, и проверка снова начинается с последнего символа.

Основные идеи алгоритма

2. Эвристика стоп-символа.

Создается массив размера |Σ| (Σ - алфавит) – это таблица стоп-символов (bad characters). В ней указывается последняя позиция в шаблоне (исключая последнюю букву) каждого из символов алфавита. Для всех символов, не вошедших в шаблон, ставится значение m. Предположим, что у нас не совпал символ сиз текста на очередном шаге с символом из шаблона. Очевидно, что в таком случае мы можем сдвинуть шаблон до первого вхождения этого символа св шаблоне, потому что совпадений других символов точно не может быть. Если в шаблоне такого символа нет, то можно сдвинуть весь шаблон полностью.

Эвристика стоп-символа

- 1-ый случай: не совпавший символ присутствует в подстроке

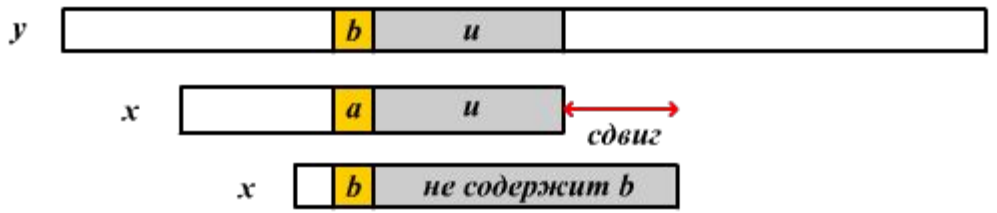

- 2-ой случай: не совпавший символ отсутствует в подстроке

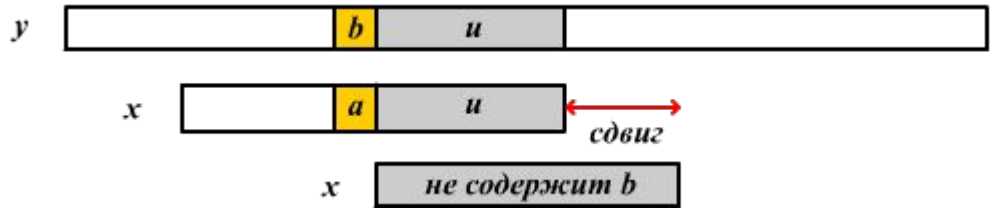

Основные идеи алгоритма

3. Эвристика хорошего суффикса.

Если при сравнении текста и шаблона совпало один или больше символов, шаблон сдвигается в зависимости от того, какой суффикс совпал.

Если существуют такие подстроки равные u, что они полностью входят в x и идут справа от символов, отличных от x[i], то сдвиг происходит к самой правой из них, отличной от u.

Эвристика хорошего суффикса

1-ый случай: суффикс u присутствует еще раз в строке слева

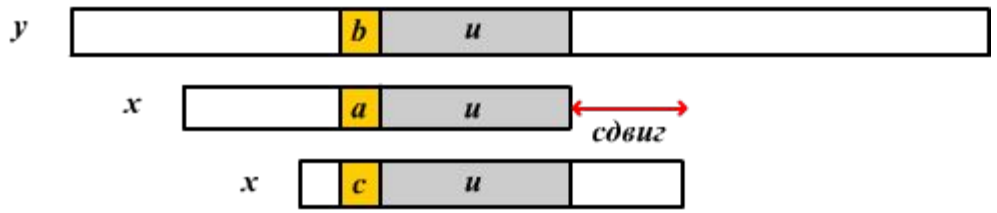

2-ой случай: существует префикс v – подстрока суффикса u

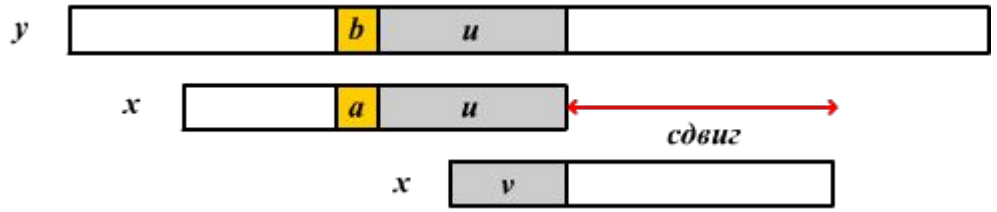

Реализация

```
private static int[] preBmBc(String x) {
    int[] table = new int[26];

    for (int i = 0; i < 26; i++) {
        table[i] = x.length();
        iterations++;
    }

    for (int i = 0; i < x.length() - 1; i++) {
        table[x.charAt(i) - 'a'] = x.length() - 1 - i;
        iterations++;
    }

    return table;
}
```

- Создание таблицы стоп-символов
- Асимптотика: O(m+|Σ|) [в данном случае |Σ| = 26]

Реализация

```
private static boolean isPrefix(String x, int p) {
    int j = 0;
    for (int i = p; i < x.length(); i++) {
        if (x.charAt(i) != x.charAt(j)) {
            return false;
        }
        j++;
        iterations++;
    }
    return true;
}
```

- Функция, проверяющая, что подстрока x[p…m−1] является префиксом шаблона x.
- Асимптотика: O(m−p)

Реализация

```java
private static int suffixLength(String x, int p) {
    int len = 0;
    int i = p;
    int j = x.length() - 1;
    while (i >= 0 && x.charAt(i) == x.charAt(j)) {
        len++;
        i--;
        j--;
        iterations++;
    }
    return len;
}
```

- Функция, возвращающая для позиции p длину максимальной подстроки, которая является суффиксом шаблона x.
- Асимптотика: O(m−p)

Реализация

```
private static int[] preBmGs(String x) {
    int[] table = new int[x.length()];
    int lastPrefixPos = x.length();
    for (int i = x.length() - 1; i >= 0; i--) {
        if (isPrefix(x, p: i + 1)) {
            lastPrefixPos = i + 1;
        }
        table[x.length() - 1 - i] = lastPrefixPos - i + x.length() - 1;
        iterations++;
    }
    for (int i = 0; i < x.length() - 1; i++) {
        int slen = suffixLength(x, i);
        table[slen] = x.length() - 1 - i + slen;
        iterations++;
    }
    return table;
}
```

- Функция для вычисления сдвигов хороших суффиксов. Требует O(m) времени, несмотря на циклы в вызываемых функциях, из-за того, что каждый внутренний цикл в худшем случае будет выполняться на каждой позиции i не больше, чем i раз. Получается натуральный ряд, сумма m первых членов которого $m \cdot (m-1)/2$.
- Асимптотика: $O(m^2)$ в худшем случае

Реализация и оценка асимптотики

```java
public static ArrayList<Integer> algorithm(String y, String x) {
    ArrayList<Integer> answer = new ArrayList<>();
    iterations = 0;
    if (x.length() == 0 || y.length() < x.length()) {
        answer.add(-1);
        iterations = 1;
        return answer;
    }

    int[] bmBc = preBmBc(x);
    int[] bmGs = preBmGs(x);
    for (int i = x.length() - 1; i < y.length(); ) {
        int j = x.length() - 1;
        while (x.charAt(j) == y.charAt(i)) {
            if (j == 0) {
                answer.add(i);
                iterations++;
                break;
            }
            --i;
            --j;
            iterations++;
        }
        i += Math.max(bmGs[x.length() - 1 - j], bmBc[y.charAt(i) - 'a']);
    }
    if (answer.isEmpty()) {
        answer.add(-1);
        iterations++;
    }
    return answer;
}
```

- Фаза предварительных вычислений требует $O(m^2 + \sigma)$ времени и памяти.
- В худшем случае поиск требует $O(m \cdot n)$ сравнений, так как сравнения будут произведены по всей строке.
- В лучшем случае требует $\Omega(n/m)$ сравнений.
- m – длина подстроки
- n – длина исходной строки

Графики

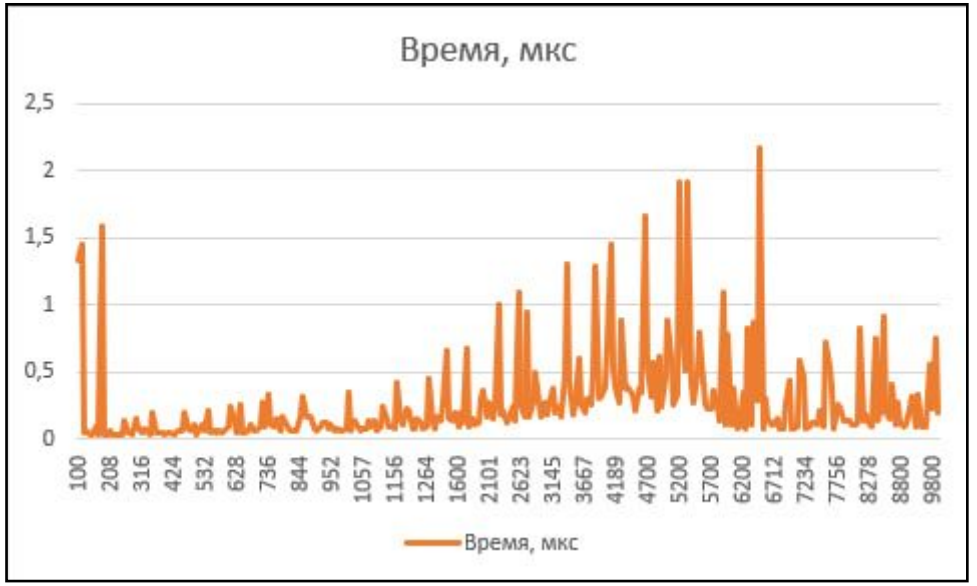

Входные данные: 1-ая строка (текст) размером от 100 до 10000, состоящая из прописных латинских букв; 2-ая строка из 1-7 символов (подстрока, или шаблон)

Выводы

Преимущества:

- Алгоритм Бойера-Мура на хороших данных очень быстр, а вероятность появления плохих данных крайне мала. Поэтому он оптимален в большинстве случаев, когда нет возможности провести предварительную обработку текста, в котором проводится поиск.

Недостатки:

- Алгоритм Бойера-Мура не расширяется до приблизительного поиска и поиска любой строки из нескольких.
- На больших алфавитах (например, Юникод) может занимать много памяти. В таких случаях либо обходятся хэш-таблицами, либо дробят алфавит, рассматривая, например, 4-байтовый символ как пару двухбайтовых.
- На искусственно подобранных неудачных текстах скорость алгоритма Бойера-Мура серьёзно снижается. (Пример: Исходный текст **bb…bb** и шаблон ab…ab.)

Ссылка на репозиторий